

학사학위논문

머신러닝을 이용한 청소년 비만 분석

2023. 12. 04

忠 北 大 學 校

빅데이터 專攻

李 光 鎮

머신러닝을 이용한 청소년 비만 분석

지도교수 Aziz Nasridinov

이 논문을 학사학위 논문으로 제출함

2023年 12月

충북대학교

빅데이터 융합전공

이광진

이광진의 학사학위논문을 인준함.

지도교수 Aziz Nasridinov (인)

2023年 12月

충북대학교 빅데이터 융합전공

<목 차>

I . 서론	1
1. 연구의 필요성	1
2. 연구의 목적	2
3. 연구 구성	2
II . 이론적 배경	3
1. 비만의 정의	3
2. 비만에 의한 발생 질환	3
3. 청소년 비만의 문제점	4
4. 청소년 비만 현황	4
5. 선행 연구	5
III . 연구 방법	6
1. 데이터의 수집	7
2. 데이터 전처리	8
3. 데이터 시각화	15
4. 데이터 분류분석	20
IV . 연구 결과	27
1. 연구 요약	27
2. 연구의 한계점	29
참고문헌	30

<표 목차>

[표1] 우리나라 중·고등학생의 연도에 따른 비만율(06~22년)	4
[표2] 열이 가지는 범주	8
[표3] 남학생의 bmi에 따른 bmi 등급	11
[표4] 여학생의 bmi에 따른 bmi 등급	11

<그림 목차>

[그림1] 중고등학생 비만율 현황	5
[그림2] 연구 방법 모형도	6
[그림3] ‘교육부_학생 건강검사 표본조사 rawdata_20211231’ 데이터	7
[그림4] 데이터 열 이름 변경 전, 변경 후	9
[그림5] 불필요한 열 제거 후 데이터	9
[그림6] 필요한 행 선택 후 데이터	10
[그림7] 기존 변수로 추가된 파생 변수	10
[그림8] 수치화된 데이터	12
[그림9] 결측값 확인	13
[그림10] 인코딩 데이터	13
[그림11] 이상치 데이터 제거 전, 제거 후	14
[그림12] 데이터 정규화 전, 후	14
[그림13] 데이터 전처리 전, 후	15
[그림14] bmi 등급에 따른 Pie Chart	16
[그림15] 성별, 도시 규모에 따른 비정상 bmi 등급 barplot	16
[그림16] 시도에 따른 비정상 bmi 등급 barplot	17
[그림17] 성별에 따라 이상 치아의 유무에 따른 bmi 등급	17
[그림18] 도시 규모별 학교생활에 따른 bmi	18
[그림19] 도시 규모별 가정에 따른 bmi sunburst	19
[그림20] K에 따른 KNN 분류 정확도	21
[그림21] n에 따른 Randomforest 분류 정확도	21
[그림22] n에 따른 AdaBoost 분류 정확도	21
[그림23] 모든 열들을 이용한 KNN, NA, SVM, DecisionTree, Randomforest, Ada Boost 분류	21
[그림24] 모든 열을 이용한 모델의 분류 정확도 비교	22
[그림25] 열들 간의 상관관계 및 상관관계 높은 열 추출	23
[그림26] K에 따른 KNN 분류 정확도	24

[그림27] n에 따른 Randomforest 분류 정확도	24
[그림28] n에 따른 AdaBoost 분류 정확도	24
[그림29] 상관관계가 높은 열들 KNN, NA, SVM, DecisionTree, Randomforest, AdaBoost 분류	24
[그림30] 상관관계 높은 열을 이용한 모델의 분류 정확도 비교	25
[그림31] 모델 Stacking	26
[그림32] Stacking 후 모델의 분류 정확도 비교	26
[그림33] 모든 열, 상관관계 높은 열, Stacking 모델 중 각각 정확도 상위 3개의 모델을 비교	28

I. 서론

1. 연구의 필요성

각종 미디어의 등장, 먹거리의 발전으로 현대 사회에서 비만은 심각한 건강 문제로 나타나고 있다. 세계 비만 연맹이 최근 발표한 ‘2023 세계 비만 지도’ 보고서에 따르면 조치가 취해지지 않고 이 현상이 이어진다면 2035년까지 세계 인구 절반 이상이 비만 또는 과체중으로 분류될 것이라고 발표하며 비만에 대한 심각성을 전달하였고 해결 방안 논의의 중요성을 강조했다. 세계보건기구(WHO)에서도 세계 비만 인구가 1900년대에 비해 3배나 늘었으며 소아·청소년의 경우 거의 10배가 증가해 매우 심각한 상황을 발표하며 비만을 유행병으로 규정했다. 성장기에 있는 소아·청소년 비만에 대한 관심이 특히 증가하고 있는데 코로나19 이후 사회적 거리 두기로 인해 야외 활동이 크게 줄었고 집에서 비대면 수업을 듣고 고칼로리인 배달 음식의 소비가 증가하며 소아·청소년 비만율이 증가했다는 연구가 발표되었다. 소아·청소년기에 쪼른 살은 성장에 긍정적인 영향을 준다는 잘못된 지식으로 소아·청소년 비만을 관리하지 않는 경우가 많은데 이를 관리하지 않고 방치하면 성인 비만으로 이어질 수 있고 다양한 만성 질환을 유발할 수 있다고 전문가들은 경고했다. (출처 : Special Broadcasting Service, 2023)

전 세계에서 소아·청소년 비만의 증가는 심각한 사회 문제로 받아들여지고 있으며 우리나라 또한 소아·청소년 비만이 급속도로 증가하며 심각하게 여겨지고 있다. 건강보험심사평가원의 2017년~2021년도 영양결핍 및 비만 진료 현황 분석에 따르면 비만으로 병원 진료를 받은 소아·청소년의 경우 2017년 2,241명에서 2021년 7,559명으로 증가해 17년도 대비 2.3배의 증가 추세를 보이며 이 같은 추세가 지속될 경우 10년 뒤엔 중·고생 3분의 1이 비만이 될 것으로 예상하고 있다.(출처 : 메디포뉴스, 2023) 이 같은 소아·청소년 비만의 수가 증가세를 보이자 최근 학생들 사이에서 인기를 끌고 있는 중화권 음식인 마라탕과 탕후루를 즐기는 문화가 소아·청소년 비만의 원인이 되고 있다며 지적되며 규제해야 한다는 목소리가 커지고 있다. 특히 과일에 설탕물, 물엿을 묻혀 만든 탕후루는 과다한 당이 들어가며 소아·청소년 비만·당뇨의 주범으로 뽑히며 국정감사에 소환되며 해당 탕후루 업체 관계자는 식약처 기준에 따라 영양성분을 표시하겠다고 밝혔다. 이는 정치권에서도 청소년 비만에 관심 가지고 있으며 비만이 더 이상 개인적인 문제가 아닌 사회적인 문제임을 나타낸다.

비만은 청소년들이 신체와 정서 발달, 부모로부터의 독립, 자아상 및 정체감 형성 등의 발달 과업을 이행할 때 경험하게 되는 불안이나 스트레스를 가중함으로써 인성 발달에 영향을 미치게 된다. (최유경, 2008) 소아·청소년의 비만 수가 지속적으로 증가하고 있고 개인은 물론 사회에도 영향을 미칠 수 있어 소아·청소년 비만의 연구가 필요하다.

2. 연구 목적

소아·청소년 비만은 성장기의 외모와 건강뿐 아니라 심리와 정서에도 영향을 미쳐 단체 생활에서도 영향을 끼칠 수 있다. 소아·청소년의 비만은 성인 비만으로도 이어질 수 있기에 건강한 개인과 사회를 만들기 위해 청소년기의 비만을 예측하고 예방하는 것이 중요하다. 소아·청소년 비만 현황을 분석하기 위해 학교에서 실시하는 청소년 건강 조사 데이터가 활용될 수 있다. 과거 청소년들의 건강 조사 데이터를 통해 청소년들의 식습관, 생활 습관, 심리, 가정생활 등의 분석을 통해 인사이트를 파악하여 비만의 위험성이 있는 청소년을 구분하는 것을 목적으로 한다. 이를 위해 공공데이터포털의 학생 건강검사 데이터를 불러와 전처리 과정 후 다양한 시각화와 머신러닝 기법들을 이용한다.

3. 연구 구성

본 논문은 4장으로 서론, 이론적 배경, 연구 방법, 연구 결과로 구성되어 있다. 서론에서는 소아·청소년 비만 연구의 필요성과 목적, 구성을 설명하고 있으며 이론적 배경에서는 비만의 정의, 비만에 의한 발생 질환, 청소년 비만의 문제점, 청소년 비만 현황, 선행 연구를 설명한다. 연구 방법에서는 해당 연구를 위한 데이터의 수집 방법과 수집한 데이터를 설명하고 데이터 전처리를 통해 불필요한 열 제거, 열 이름 수정 등의 과정을 보이고 다양한 파이썬 library를 통해 데이터 시각화를 보인다. 그 후 KNN, NA(Naive Bayes), SVM, Decision Tree, Random forest, Ada Boost를 이용해 데이터 분류를 실시하고 분류 성능을 향상시킨다. 마지막으로 연구 결과에서는 연구의 요약과 연구의 한계점을 설명하며 본 논문을 마친다.

Ⅱ. 이론적 배경

1. 비만의 정의

비만이란 체내에 지방 조직이 과다한 상태를 의미한다. 체중은 많이 나가지만 근육량이 많고 지방량이 적은 경우는 비만이라고 하지 않는다. 체질량지수(BMI : 몸무게(kg)를 키(m)의 제곱으로 나눈 값)가 25 이상이면 비만으로 정의한다. (서양인은 30으로, 인종의 차이를 고려하여 우리나라에서는 25 이상을 비만으로 정의한다.) 지방 조직의 주요 성분은 혈장으로부터 유입된 지방산과 포도당이 에스테르화한 중성지방이다. 비만은 긴 시간 동안 에너지 소비에 비해 영양소의 섭취가 많은 경우 에너지 불균형에 의해 나타난다. 선천적으로 유전자의 돌연변이에 의해 음식 섭취 조절 중추 기능에 문제가 있거나, 내분비 질환, 음식 섭취를 증가시키는 다양한 요인에 의해 나타나는 경우가 있지만, 일반적으로는 에너지 섭취량이 에너지 소비량보다 커서 발생한다. 일반적인 비만의 경우 유전과 환경의 영향이 결합 작용하여 나타난다. 특히 고칼로리의 음식이 풍부하고 과거에 비해 교통의 발달로 움직임이 크게 줄어도 불편이 없는 현대의 생활 모습이 현대인들의 비만을 증가시키고 있다. (네이버 지식백과-서울대학교병원 의학 정보)

2. 비만에 의한 발생 질환

비만은 단순히 살이 찌는 것이 아닌 각종 질병의 원인이 될 뿐 아니라 우울증 등의 정신적인 질병까지 유발할 수 있다. 정상체중과 비만인 사람을 비교할 때 제2형 당뇨병의 위험이 최대 13배까지 증가한다. 비만에 의한 당뇨병은 인슐린이 충분함에도 역할을 제대로 수행하지 못해 생기는 것으로 특히 복부 비만이 이러한 인슐린 저항과 관련이 높다. 이러한 체중 증가는 당뇨병 발생 이전부터 나타나기에 체중을 감소시키면 당뇨병 위험을 감소시킬 수 있다. 실제로 당뇨병의 예방을 위해 체중을 2.5~5.5kg 감량했을 경우 당뇨병 발생의 위험도가 30~60% 감소하게 된다. 비만은 심혈관계질환의 위험 또한 50% 높이며 모든 종류의 심혈관계질환에 의한 사망률도 50% 높일 수 있다. 비만과 혈압 간의 상관관계는 여러 연구를 통해 입증되어 있으며 비만도가 높아질수록 고혈압의 빈도도 증가하여 고혈압이 동반할 위험이 2.5~4배 더 증가한다. 하지만 체중 감량만으로 혈압이 정상으로 돌아오고 심장 크기도 줄어드는 경우가 많은데 이러한 심혈관계질환을 예방하기 위해서는 체중 관리는 반드시 필요하다고 할 수 있다. 비만은 소화기 질환에도 영향을 미친다. 대표적으로 지방간, 소화불량, 변비 등의 기능성 위장 장애와 위식도역류질환, 담석증 등이 비만과 연관되어 있다고 알려져 있다. 비만 환자들 대부분에서 지방간이 나타나는데 이는 소비하고 남은 열량을 간에 중성지방의 형태로 저장시키기 때문이다. 에너지 불균형으로 간에 지방이 과다하게 쌓이게 되면 간 기능이 악화되고 피로감이나 복부 불편감 같은 증상이 나타날 수 있다. 비만으로 인한 지방간 환자라면 체중 감량을 해야 간 기능이 회복된다. 비만 환자들의 경우 소화불량, 변비 등으로 병원을 찾는 경우가 많은데 이는 불규칙한 식사나 과식, 폭식하는 습관으로 인해 발생하는데 체중 감량과 식습관

개선으로 이를 해결할 수 있다. 비만은 심리적인 문제에도 영향을 끼치는데 특히 비만으로 인한 차별과 불이익의 경험으로 심적 영향을 미칠 수 있다. 소아, 청소년 및 청장년층에서 비만으로 인한 심리적 위축과 우울을 보이며 이러한 심리적 문제는 건강 전반에 걸쳐 부정적인 영향을 미치는 것으로 알려져 있다. 특히 사춘기 학생들은 남의 시선을 중시하여 비만인 자신의 모습을 창피하게 여겨 심리적으로 위축되는 경우가 많고 교우관계나 학업에 자신감을 잃어 불안, 우울 등이 발생하기 쉽다. 이 외에도 호흡기 질환, 여성 생식기계 이상, 근골격근계 이상 등 비만은 여러 가지 질환들이 동반될 위험이 증가한다. 비만은 그 자체로 인해 합병증이 동반하며 장애 발생률, 사망률을 유의하게 높일 뿐 아니라 외모에 부정적인 영향을 끼쳐 심리적인 문제도 발생시켜 삶의 질까지 저하시킨다. (대한 비만 학회)

3. 청소년 비만의 문제점

소아·청소년 비만에서 무증상 관상동맥질환, 무증상 동맥경화증, 혈압 증가, 지방간 질환, 철식 발병, 당뇨병, 우울, 자존감 저하, 신체 불만족이 동반한다. 소아·청소년 비만에도 성인과 마찬가지로 동일한 합병증 발생이 가능하며 소아·청소년 비만은 잠재적 질병 위험도가 더욱 높으므로 조기 관리가 중요하다. (대한 비만 협회)

소아·청소년 비만으로 인해 성인이 되어서도 지속된 경우 비만 관련 질환으로 인해 유발되는 사회경제적 손실 규모 또한 발생한다. 소아·청소년의 비만을 사회경제적 비용으로 추계하고자 앞서 설명한 비만으로 인한 질병에 따른 총 의료비를 직접비용으로, 조기 사망에 따른 소득 손실액과 입원할 경우 작업을 하지 못하는 작업 손실 비용을 간접비용으로 나눈다. 소아·청소년 비만이 지속되어 발생할 수 있는 사회경제적 비용은 해당 연구를 통한 추정치로 약 1조 3,638억 원이 유발되는 것으로 나타난다. 소아·청소년 비만의 수를 줄인다면 사회경제적 손실을 절감할 수 있는 효과를 보인다.(보건사회연구, 정영호, 임희진, 고숙자, 2010)

4. 청소년 비만 현황

[표1] 우리나라 중·고등학생의 연도에 따른 비만율(06~22년) (출처 : KOSIS)


구분	2006	2007	2008	2009	2010	2011	2012	2013
비만율	5.9	5.3	5.3	5.1	5.3	5.6	6.2	6.6
2014	2015	2016	2017	2018	2019	2020	2021	2022
6.9	7.5	9.1	10.0	10.8	11.1	12.1	13.5	12.1

KOSIS를 통해 중·고등학생의 연도에 따른 비만율을 확인한다. 2006년 중·고등학생의 비만율은 전체 학생 수의 5.9%인 반면 2022년 중·고등학생의 비만율은 12.1%로 비만율이 2배 이상 증가한 것을 알 수 있고 2021년 최고치인 13.5% 이후 2022년 약간의 감소를 보이고 있다.

[표 1]을 통해 우리나라 중·고등학생의 비만율이 꾸준한 증가세임을 확인할 수 있다. (KOSIS)


[그림1]을 보아 남학생과 여학생의 비만율 증감도 확인할 수 있는데 남학생의 경우 6.8%에서 17.5%로 11년도에 비해 21년도에 약 3배 가까이 증가하였음을 보이고 여학생의 경우 4.2%에서 9.1%로 11년도에 비해 21년도에 약 2배 이상 증가하였음을 보인다.

중고등학생 비만율 현황



연합뉴스

소아청소년 비만율 (6~18세)




자료: 질병관리청

[그림1] 중고등학생 비만율 현황 (출처 : 경향신문, 연합뉴스 2023, 자료 : 질병관리청)

5. 선행 연구

소아·청소년의 비만에 대한 관심은 지속적으로 증가하고 있으며 이에 대한 연구들도 지속되고 있다. 청소년 건강과 학교생활 적응을 살펴보았을 때 청소년 건강은 학교생활 적응에 영향을 미치는 것으로 정신 건강인 우울은 학교생활 적응에 유의한 부의 영향을 미치고 청소년 신체 건강 또한 학교생활 적응과 유의미한 결과를 보이며 신체 건강에 대한 어려움은 열등감으로 인한 대인관계 장애, 또래 집단으로부터의 소외감, 우울 등의 부정적인 심리 사회적 영향으로 인해 학교생활 적응에 어려움을 겪는다. (장아영, 2018) 연구 참여자의 일반적 특성에서 정상체중 청소년과 비만 청소년의 분포에서 가정 수입이 적을수록 비만 분포가 증가하였고 아버지의 학력에 따라 비만 분포에 유의한 차이를 보였으며 비만 청소년들은 정상체중 청소년들에 비해 신체활동을 하는데 있어 외적규제나 의무감규제 등에 의존하는 반면 정상체중 청소년들은 내적동기에 의해 신체활동에 참여하는 것으로 확인된다.(이은숙, 2008) 비비만 청소년과 비만 청소년의 우울은 다른 연구와 다르게 유의미한 차이가 나타나지 않았으나 비만군이 비비만군에 비해 평균 점수가 낮았고 비비만 청소년과 비만 청소년의 성격 특성 중 외향성과 그 하위 요인 사교성, 명량성, 리더쉽, 자극-추구 모두에서 유의한 차이는 없었고 지적 개방성과 그 하위 요인에 차이를 알아보았으나 역시 유의미한 차이가 없었으며 친화성, 성실성 또한 유의미한 차이는 없었지만 평균점수에서 다소 차이를 보였다.(최유경, 2008)

Ⅲ. 연구 방법



[그림2] 연구 방법 모형도

본 논문의 연구 방법 모형도는 위의 [그림2]와 같다. 학생건강정보센터의 초기 데이터를 불러와 위와 같은 전처리 과정을 거치고 전처리한 데이터를 이용해 모델을 생성하기 위해 train 데이터와 test 데이터를 7 : 3의 비율로 나눈다. train 데이터로 6가지의 분류 모델을 훈련하고 test 데이터에 적용해 정확도를 확인한다. 그 후 모델 성능 향상을 위해 상관관계 높은 열 추출, Stacking을 실시하고 성능이 좋은 모델을 선택한다.

1. 데이터 수집

본 논문은 학생건강정보센터 (<https://schoolhealth.kr/index.do>) 에서 제공하는 설문지 형식의 데이터로 '교육부_학생 건강검사 표본조사 rawdata_20211231'를 이용하여 분석하였다.

#	Column	Non-Null Count	Dtype		
0	학년도	97787 non-null	int64	82	안전벨트착용
1	최종가중치	97787 non-null	float64	83	안전장비착용
2	학교ID	97787 non-null	int64	84	외상치료경험
3	strata	97787 non-null	int64	85	하루tv시청2시간이상
4	도시규모	97787 non-null	object	86	하루2시간이상게임_초
5	공학여부	97787 non-null	object	87	하루2시간이상게임_중고
6	시도	97787 non-null	object	88	음란물채팅
7	학교급	97787 non-null	object	89	괴롭힘따돌림_초
8	학년	97787 non-null	int64	90	괴롭힘따돌림_중고
9	반	97787 non-null	int64	91	현금갈취
10	순번	97787 non-null	int64	92	신체접촉
11	성별	97787 non-null	object	93	가출생각_초
12	생년월일	97787 non-null	int64	94	가출생각_중고
13	건강검진일	97786 non-null	float64	95	고민상담대상
14	키	97787 non-null	float64	96	가정문제각정
15	몸무게	97787 non-null	float64	97	가족지지
16	척추	32230 non-null	object	98	체벌경험
17	시력_나안_좌	20826 non-null	float64	99	폭력위험
18	시력_나안_우	20826 non-null	float64	100	상담희망_초
19	시력_교정_좌	11590 non-null	float64	101	상담희망_중고
20	시력_교정_우	11590 non-null	float64	102	가족흡연
21	안질환	32492 non-null	object	103	가족음주
22	청력_좌	32441 non-null	object	104	흡연음주전문가상담희망
23	청력_우	32441 non-null	object	105	무기력감
24	귀병	32492 non-null	object	106	수업태도교정
25	코병	32490 non-null	object	107	과잉행동
26	목병	32491 non-null	object	108	주의력산만
27	피부병	32491 non-null	object	109	성문제전문가상담희망
28	요단백	32350 non-null	object	110	진로고민
29	요장질	32338 non-null	object	111	상담요청_초
30	혈당(식전)(mg_d1)	5084 non-null	float64	112	상담요청_중고
31	총콜레스테롤(mg_d1)	5092 non-null	float64		
32	hdl(mg_d1)	4979 non-null	float64		
33	중성지방(mg_d1)	5025 non-null	float64		
34	ldl(mg_d1)	4955 non-null	float64		
35	AST(U_L)	5074 non-null	float64		
36	ALT(U_L)	5069 non-null	float64		
37	혈색소(g_d1)	5084 non-null	float64		
38	결핵흉부방사선검사	20032 non-null	object		
39	수축기	31969 non-null	float64		

(중략)

dtypes: float64(75), int64(7), object(31)
memory usage: 84.3+ MB

[그림3] '교육부_학생 건강검사 표본조사 rawdata_20211231' 데이터

해당 데이터를 표현하는 [그림3]은 교육부에서 실시한 학생 건강검사 데이터로 흔히 학교에서 실시하는 건강 검진 데이터이다. 데이터의 열이 113개가 있고 분석에 필요한 데이터들 또한 제한되어 있기 때문에 모든 열들에 대한 소개는 불가능하다. 따라서 열들을 구분하여 소개한다. 학생들의 개인 정보인 [학년, 학교, 도시, 성별, 생년월일] 등이 있으며 건강 검진을 통해 알 수 있는 [키, 몸무게, 시력, 청력, 혈당, 중성지방, 수축기, 이완기, 이상 치아 개수] 등 학생들의 건강 정보에 대한 열을 가지고 있다. 학생들의 건강 정보는 대부분 float타입으로 수치형 변수임을 알 수 있고 해당 열들에 결측값들이 많이 존재하여 이를 정리해 줄 필요가 있다. 학생들의 생활 습관을 알 수 있는 열은 [라면, 음료수, 아침 식사, 다이어트 경험, 운동, 수면량, 씻기, 안전벨트, 게임이용시간] 등이 있고 학생들의 가정과 심리 상태를 알 수 있는 [괴롭힘, 현금갈취, 체벌경험, 상담희망, 가족흡연, 가족음주, 무기력감] 등의 열들이 있다. 학생들의 생활습관과 가정, 심리 등을 알 수 있는 열들은 학생들이 직접 설문을 작성하는 항목으로 (1, 2) 또는 (1, 2, 3, 4) 중 하나를 선택하는 명목형 변수로 되어 있다. 해당 열들 또한 결측값들이 존재하여 이를 처리할 필요가 있다. 기본적인 정보(키, 학년, 몸무게 등)를 제외하고는 대부분에서 결측값들(실제로 입력되지 않은 부분도 있지만 초등학생과 중, 고등학생의 설문이 합쳐져 있기에 빠져있는 데이터도 있다.)이 보이는 것을 확인할 수 있고 113개의 열과

97787개의 데이터가 있음을 알 수 있다. int타입이 7개, object타입이 31개, float타입이 75개로 불필요한 열 제거, 분석에 필요한 데이터 선택, 타입변경 등 공공데이터포털에서 제공한 데이터 정보를 제대로 확인하기 위해 데이터 전처리 과정이 필요해 보인다.

데이터 설명 코드북에는 120개의 열이 있다고 하지만 실제로는 [호흡기, 비교기, 순환기, ...] 등의 열이 없어 113개의 열이 있음을 확인할 수 있다.

학생들의 건강 상태, 생활 습관, 학교생활, 가정 및 심리 상태가 학생들의 bmi에 어떤 영향을 미치는지 분석하기를 원하기에 학생들의 키와 몸무게를 통해 bmi라는 새로운 변수를 생성하고 bmi를 [저체중, 정상, 과체중, 비만]으로 나누는 bmi_등급 변수를 생성하여 bmi와 해당 열들의 관계를 분석한다.

해당 데이터의 범주형 변수들은 각 변수에 따라 범주가 설명하는 값들이 다르다. 이를 [표2]로 간략하게 표현하였다.

[표2] 열이 가지는 범주

열 이름 \ 범주	1	2	3	4
라면, 음료수, 패스트푸드, 육류, 우유 유제품, 과일, 채소(김치제외)	먹지 않음.	1-2번	3-5번	매일 먹음.
아침식사	거의 꼭 먹음.	대체로 먹음.	대체로 안 먹음.	거의 안 먹음.
다이어트경험_답변1~4	아무것도 안함.	식단을 조절한다.	약을 먹는다.	운동을 한다.
주3회이상운동	거의 안 했음.	1-2일 정도.	3-4일 정도.	5일 이상
하루수면량	6시간 이내.	6-7시간.	7-8시간.	8시간 이상
하루tv시청2시간이상, 하루2시간이상게임_초, 괴롭힘따돌림_초, 현금갈취, 신체접촉, 가출생각_초, 가족지지, 체벌경험, 학교문제상담희망_초, 가족흡연, 가족음주, 무기력감, 수업태도교정, 상담요청_초	예	아니오		

2. 데이터 전처리

분석에 앞서 데이터의 rename, 불필요한 열 제거, 결측값 제거, 이상치 처리 등 데이터 전처리를 하였다.

(1) 열 이름 수정 (Rename)

해당 데이터는 97,787명의 학생들을 대상으로 하여 건강검사를 실시한 데이터로 초등학교부터 고등학교까지의 데이터가 존재한다. 키, 학교, 몸무게 등 기본적인 정보를 설명하는 열은 모든 학생들의 데이터를 가지고 있지만 열들에 따라 약 3만 개의 데이터가 초등학교를, 6만개의 데이터가 중, 고등학교를 설명하는 열로 구분되어 있기 때문에 초등학교 데이터를 활용하기 위해 중, 고등학교 데이터를 제외하기 위한 작업을 한다. [그림4]에서 열들의 이름이 초

등학생과 중, 고등학생이 구분된 열들이 있는 반면 구분이 안된 열들이 존재하기에 이러한 열들을 구분해 준다. 열 이름에 _초, _중고로 구분되어 있는 열들 이외에 구분되지 않은 열들의 이름을 rename 하였다.

```
'하루tv시청2시간이상', '하루2시간이상게임_초', '하루2시간이상게임_중고', '음란물채팅', '괴롭힘따돌림_초',
'괴롭힘따돌림_중고', '현금갈취', '신체접촉', '가출생각_초', '가출생각_중고', '고민상담대상', '가정문제걱정',
'가족지지', '체벌경험', '폭력위협', '상담희망_초', '상담희망_중고', '가족흡연', '가족음주',
'흡연음주전문가상담희망', '무기력감', '수업태도교정', '과잉행동', '주의력산만', '성문제전문가상담희망', '진로고민',
'상담요청_초', '상담요청_중고'],
dtype='object')

'하루tv시청2시간이상_초', '하루2시간이상게임_초', '하루2시간이상게임_중고', '음란물채팅_중고', '괴롭힘따돌림_초',
'괴롭힘따돌림_중고', '현금갈취_초', '신체접촉_초', '가출생각_초', '가출생각_중고', '고민상담대상_중고',
'가정문제걱정', '가족지지_초', '체벌경험_초', '폭력위협_중고', '상담희망_초', '상담희망_중고', '가족흡연_초',
'가족음주_초', '흡연음주전문가상담희망_중고', '무기력감_초', '수업태도교정_초', '과잉행동_부모님란',
'주의력산만_부모님란', '성문제전문가상담희망_중고', '진로고민_중고', '상담요청_초', '상담요청_중고'],
dtype='object')
```

[그림4] 데이터 열 이름 변경 전, 변경 후

이름이 잘 수정되었음을 확인한다.

(2) 불필요한 열 제거

bmi에 대해 분석을 할 예정이기에 bmi와 관련이 없다고 생각되는 불필요한 열들을 제거하는 작업이 필요하다. 총 113개의 열이 존재하여 health 데이터의 불필요한 열을 제외하기 위해 drop()을 사용할 수 있지만 해당 데이터는 열들이 너무 많고 하나씩 확인하기 어렵기에 health 데이터의 columns를 가져와 불필요한 열들을 #을 통해 열들을 하나씩 생략하여 health_drop으로 새롭게 정의하였다. [_중고] 가 붙은 데이터들은 중, 고등학생을 의미하는 데이터로 초등학생들의 bmi를 분석하려는 해당 프로젝트에서는 필요가 없는 열들이기에 모두 제거해 주었다. [혈당, 총콜레스테롤, 중성지방,...] 등의 데이터들은 bmi와 연관이 있어 보이지만 결측값이 너무 많아 분석에 적용하기 어려울 것으로 판단하여 제거하였다. 시력, 청력, 궤병, 콧병의 경우 bmi와 연관이 없다고 판단되어 제거하였다. 이상 치아는 bmi와 연관이 없다고 생각되지만 비만은 주로 에너지 소비량 대비 과도한 음식물 섭취로 발생하여 음식물 섭취와 치아는 큰 연관이 있기에 식습관과 관련이 있다고 판단하여 열을 제거하지 않았다. 그 외에는 주관적인 판단으로 bmi와 연관이 없다고 생각하여 제거하였다. [그림5]는 불필요한 열 제거 후 {도시규모 ~ 상담요청_초}의 46개 열이 남은 것을 보인다.

```
Index(['도시규모', '시도', '학교급', '학년', '성별', '키', '몸무게', '수축기', '이완기', '총치치아_유무',
'총치치아_개수_상', '총치치아_개수_하', '충치발생위험치아_유무', '충치발생위험치아_개수_상',
'충치발생위험치아_개수_하', '결손치아영구치아_유무', '결손치아영구치아_개수_상', '결손치아영구치아_개수_하',
'라면', '음료수', '패스트푸드', '육류', '우유유제품', '과일', '채소(김치제외)', '아침식사',
'다이어트경험_답변1', '다이어트경험_답변2', '다이어트경험_답변3', '다이어트경험_답변4', '주3회이상운동_초',
'하루수면량', '하루tv시청2시간이상_초', '하루2시간이상게임_초', '상담희망_초', '가족흡연_초', '가족음주_초',
'괴롭힘따돌림_초', '현금갈취_초', '신체접촉_초', '가출생각_초', '가족지지_초', '체벌경험_초', '무기력감_초',
'수업태도교정_초', '상담요청_초'],
dtype='object')
```

[그림5] 불필요한 열 제거 후 데이터

(3) 필요한 행 선택

해당 데이터는 학교급이 ['초', '중', '고']로 구분되어 있다. 초등학생의 비만 데이터 분석을 위해 '학교급'이 '초'인 행들을 추출한다. [그림6]을 통해 총 97,787개의 데이터 중 38,448개의 데이터가 추출된 것이 보인다.

```
0      초
1      초
2      초
3      초
4      초
...
38443   초
38444   초
38445   초
38446   초
38447   초
Name: 학교급, Length: 38448, dtype: object
```

[그림6] 필요한 행 선택 후 데이터

(4) 파생 변수 추가

[그림7]은 파생 변수를 추가한 것으로 bmi는 몸무게/ $(\frac{\text{키}}{100})^2$ 이므로 기존 데이터의 키와 몸무게 변수를 이용해 학생에 따른 파생 변수 bmi를 생성한다. [그림7]의 왼쪽 그림을 통해 38,448명의 학생들에 따라 키와 몸무게마다 bmi가 생성된 것을 볼 수 있다. 본 논문에서는 학생들의 bmi의 예측이 아닌 bmi를 이용해 학생들을 비만, 과체중, 정상, 저체중으로 분류하여 등급을 예측하는 분석을 실시할 것이기 때문에 생성된 bmi에 따른 bmi_등급 파생 변수를 생성한다. bmi_등급은 '저체중', '정상', '과체중', '비만'으로 나누며 저체중, 정상, 과체중, 비만은 나이와 성별에 따라 bmi가 가지는 값이 다르므로 나이와 성별에 따른 bmi 등급의 기준을 다르게 하여 구분한 것을 [표3], [표4]로 표현하였다.

0	16.528926	0	정상
1	17.888637	1	정상
2	18.269083	2	정상
3	15.802112	3	정상
4	16.148774	4	정상
	...		...
38443	23.808022	38443	과체중
38444	17.426325	38444	정상
38445	20.692479	38445	정상
38446	21.316255	38446	정상
38447	18.569532	38447	정상

Name: bmi, Length: 38448, dtype: float64 Name: bmi_등급, Length: 38448, dtype: object

[그림7] 기존 변수로 추가된 파생 변수

[표3]과 [표4]는 남학생과 여학생의 bmi에 따른 bmi 등급을 표현한 표이다. 남학생, 여학생 모두에서 학년이 증가할수록 bmi 등급이 가지는 bmi의 수치가 증가하는 것을 볼 수 있고 동일 학년의 경우 남학생의 bmi 등급이 가지는 bmi의 수치가 여학생의 bmi 등급이 가지는 bmi 수치보다 더 높은 것을 알 수 있다. [표3], [표4]를 기준으로 [그림7]의 오른쪽 그림과 같이 bmi_등급 변수를 생성하였고 각 학생의 bmi에 따른 bmi_등급을 추가하였다.

[표3] 남학생의 bmi에 따른 bmi 등급

남자 \ BMI	저체중	정상	과체중	비만
1학년	$BMI < 13.93$	$13.93 \leq BMI < 18.86$	$18.86 \leq BMI < 20.93$	$20.93 \leq BMI$
2학년	$BMI < 14.06$	$14.06 \leq BMI < 19.80$	$19.80 \leq BMI < 22.13$	$22.13 \leq BMI$
3학년	$BMI < 14.27$	$14.27 \leq BMI < 20.76$	$20.76 \leq BMI < 23.34$	$23.34 \leq BMI$
4학년	$BMI < 14.57$	$14.57 \leq BMI < 21.71$	$21.71 \leq BMI < 24.48$	$24.48 \leq BMI$
5학년	$BMI < 14.93$	$14.93 \leq BMI < 22.57$	$22.57 \leq BMI < 25.5$	$25.5 \leq BMI$
6학년	$BMI < 15.35$	$15.35 \leq BMI < 23.32$	$23.32 \leq BMI < 26.35$	$26.35 \leq BMI$

[표4] 여학생의 bmi에 따른 bmi 등급

여자 \ BMI	저체중	정상	과체중	비만
1학년	$BMI < 13.63$	$13.63 \leq BMI < 18.27$	$18.27 \leq BMI < 20.05$	$20.05 \leq BMI$
2학년	$BMI < 13.77$	$13.77 \leq BMI < 19.05$	$19.05 \leq BMI < 21.05$	$21.05 \leq BMI$
3학년	$BMI < 14.01$	$14.01 \leq BMI < 19.88$	$19.88 \leq BMI < 22.09$	$22.09 \leq BMI$
4학년	$BMI < 14.33$	$14.33 \leq BMI < 20.71$	$20.71 \leq BMI < 23.08$	$23.08 \leq BMI$
5학년	$BMI < 14.73$	$14.73 \leq BMI < 21.51$	$21.51 \leq BMI < 23.99$	$23.99 \leq BMI$
6학년	$BMI < 15.20$	$15.20 \leq BMI < 22.22$	$22.22 \leq BMI < 24.77$	$24.77 \leq BMI$

(5) 수치 데이터

[그림8]은 describe()로 수치형 데이터를 보이며 이를 통해 각 열들의 개수, 평균, 표준편차, 최소, 최대, 제1사분위-제3사분위의 통계 값을 확인한다. 학년은 1학년부터 6학년까지 있음을 확인할 수 있고 평균이 3.5인 것을 보아 고학년이 조금 더 많음을 확인할 수 있다. 키의 평균은 13cm이고 키가 가장 작은 학생은 102cm, 가장 큰 학생은 180cm로 약 80cm의 큰 차이를 보이는 것을 알 수 있다. 몸무게의 평균은 37kg이고 몸무게의 최소가 14.6kg, 최대가 110kg으로 약 100kg의 차이를 보이며 키보다 몸무게의 차이가 더 큰 것을 확인할 수 있다. 수축기의 경우 평균이 97로 정상 범주를 잘 표현하고 있지만 최댓값이 914, 최솟값이 11로 이상치가 확인되는 것을 알 수 있다. 이는 기계 오류 또는 작성 오류로 판단되므로 데이터 전처리 과정에서 처리 해주어야 한다.

이완기 또한 최댓값이 663, 최솟값이 6으로 이상치를 가지고 있다. 따라서 데이터 전처리 과정에서 처리 해줘야 한다. 이상이 있는 치아 상_하 개수들의 평균을 보면 모두 0.6개 미만임을 확인할 수 있다. 반면 최댓값은 11, 9, 8로 높은 값을 보이는데 이는 대부분의 학생들이 이상이 있는 치아가 없으나 소수의 학생들에게서 이상 있는 치아가 많이 확인되는 것을 알 수 있다. bmi의 평균은 약 19이고 bmi의 최댓값이 38.8, 최솟값이 10.4로 약 4배 가까운 차이를 보이고 있는 것을 확인할 수 있다. 키, 몸무게와 수축기, 이완기의 값을 보면 다른 열들의 값보다 매우 큰 값을 가지는 것을 보인다. 키와 몸무게는 파생 변수 bmi를 생성 후 분석에서 제거할 예정으로 정규화가 필요하지 않지만 수축기, 이완기의 경우 정규화가 필요해 보인다. 또한 학년, 키, 몸무게 열들의 데이터 개수를 보면 38,448인 반면 이외의 열들은 데이터의 개수가 일정하지 않아 결측값들이 많이 존재하는 것을 알 수 있다. 이들 결측값 또한 제거한다. [가족음주, 괴롭힘, 현금갈취, ... , 상담요청]의 경우 평균값이 약 1.9로 대부분 2의 값을 가지는 것을 보아 대부분의 청소년들이 [가족음주, 괴롭힘, 현금갈취, ... , 상담요청]에 문제가 없고 도움이 필요하지 않은 것을 알 수 있어 bmi 등급에 영향을 끼치지 못할 것으로 보인다.

	가족음주_초	괴롭힘따돌림_초	현금갈취_초	신체접촉_초	가출생각_초	가족지지_초	체벌경험_초	무기력감_초	수업태도교정_초	상담요청_초	bmi
	37329.000000	37332.000000	37329.000000	37329.000000	37332.000000	37346.000000	37346.000000	37326.000000	37347.000000	37335.000000	38448.000000
	1.857885	1.968311	1.996196	1.987811	1.950230	1.104241	1.971965	1.961823	1.964522	1.973189	19.058053
	0.349172	0.175172	0.061560	0.109730	0.217472	0.305578	0.165075	0.191626	0.184987	0.161534	3.858631
	1.000000	1.000000	1.000000	1.000000	1.000000	1.000000	1.000000	1.000000	1.000000	1.000000	10.455774
	2.000000	2.000000	2.000000	2.000000	2.000000	1.000000	2.000000	2.000000	2.000000	2.000000	16.083750
	2.000000	2.000000	2.000000	2.000000	2.000000	1.000000	2.000000	2.000000	2.000000	2.000000	18.290888
	2.000000	2.000000	2.000000	2.000000	2.000000	1.000000	2.000000	2.000000	2.000000	2.000000	21.338249
	2.000000	2.000000	2.000000	2.000000	2.000000	2.000000	2.000000	2.000000	2.000000	2.000000	38.806522
학년	키	몸무게	수축기	이완기	충치치아_개수_상	충치치아_개수_하	충치발생위험치아_개수_상	충치발생위험치아_개수_하	결손치아영구치아_개수_상	결손치아영구치아_개수_하	
count	38448.000000	38448.000000	38448.000000	12105.000000	12105.000000	18568.000000	18399.000000	17365.000000	17417.000000	14720.000000	14775.000000
mean	3.497321	137.735079	37.094083	97.099314	59.295679	0.537268	0.498179	0.350993	0.368663	0.010870	0.020846
std	1.703667	12.275926	12.476537	13.288884	10.331656	1.067804	0.993448	0.744623	0.753716	0.133484	0.185719
min	1.000000	101.900000	14.600000	11.000000	6.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000
25%	2.000000	128.000000	27.400000	90.000000	55.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000
50%	4.000000	137.100010	34.799999	98.000000	60.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000
75%	5.000000	147.000000	44.400002	104.000000	64.000000	1.000000	1.000000	0.000000	0.000000	0.000000	0.000000
max	6.000000	179.800000	110.600000	914.000000	663.000000	11.000000	9.000000	8.000000	8.000000	4.000000	5.000000

[그림8] 수치화된 데이터

(6) 데이터 타입 변경, 결측값 제거 및 대체

해당 건강검사 데이터는 설문 조사 형식의 데이터로 '라면, ..., 상담요청_초' 까지 (1, 2) 또는 (1, 2, 3, 4)와 같이 항목을 선택하는 범주형 변수이다. 범주형 변수와 수치형 변수에 대해 결측값들을 제거한 후 데이터 타입을 float에서 int로 변환한다. 다이어트경험_답변의 경우 다이어트 경험의 더미 변수로 [답변1 : 하지 않음], [답변2 : 식단을 조절한다.], [답변3 : 약을 먹는다.], [답변4 : 운동을 한다.]로 구성되어 답변 1에 해당하면 1, 그렇지 않으면 0 답변 2에 해당하면 2, 그렇지 않으면 0 답변 3에 해당하면 1, 그렇지 않으면 0 답변 4에 해당하면 4, 그렇지 않으면 0으로 표현되어 있는데 각각의 답변에 해당하면 1, 아니면 0으로 처리한다. 데이터의 결측값들이 잘 제거되었는지 확인한다. [그림9]에서 isnull().sum() 함수를 통해 해당 데이터에 결측값이 없는 것을 알 수 있다.

도시규모	0	채소(김치제외)	0
시도	0	아침식사	0
학교급	0	다이어트경험_답변1	0
학년	0	다이어트경험_답변2	0
성별	0	다이어트경험_답변3	0
키	0	다이어트경험_답변4	0
몸무게	0	주3회이상운동_초	0
수축기	0	하루수면량	0
이완기	0	하루tv시청2시간이상_초	0
충치치아_유무	0	하루2시간이상게임_초	0
충치치아_개수_상	0	상담희망_초	0
충치치아_개수_하	0	가족흡연_초	0
충치발생위험치아_유무	0	가족음주_초	0
충치발생위험치아_개수_상	0	괴롭힘따돌림_초	0
충치발생위험치아_개수_하	0	현금갈취_초	0
결손치아영구치아_유무	0	신체접촉_초	0
결손치아영구치아_개수_상	0	가솔생각_초	0
결손치아영구치아_개수_하	0	가족지지_초	0
라면	0	체벌경험_초	0
음료수	0	무기력감_초	0
패스트푸드	0	수업태도교정_초	0
육류	0	상담요청_초	0
우유유제품	0	bmi	0
과일	0	bmi_등급	0
		dtype: int64	

[그림9] 결측값 확인

(7) 인코딩

분석의 편의를 위해 충치 치아, 충치 발생 위험 치아, 결손 치아 영구 치아 유무에 따라 무: 0, 유:1로 부호화하였다. [그림10]에서 인코딩되었음을 확인한다.

충치치아_유무	충치발생위험치아_유무	결손치아영구치아_유무	
0	1	1	0
1	0	0	0
2	0	1	0
3	0	0	0
4	0	0	0
...	...	...	...
4760	0	0	0
4761	0	0	0
4762	0	0	0
4763	0	0	0
4764	0	1	0


4765 rows × 3 columns

[그림10] 인코딩 데이터

(8) 이상치 제거

이완기의 boxplot을 그려보았다. [그림11]의 왼쪽 그림을 보면 다수의 이상치가 발견되고 그 중 20 미만의 이상치가 발견된다. 20 미만의 이상치를 제외한 다른 이상치들의 경우 실제로 저혈압이나 고혈압의 경우 이완기의 값이 30~40 또는 80 이상의 값을 가질 수 있으므로 이상치를 제거하기엔 무리가 있다. 반면 저혈압의 경우라고 20 미만의 수치는 오류라고 판단되고 분석에 영향을 끼칠 수 있으므로 20 미만의 이상치를 제거한다.

이상치를 제거한 후 boxplot을 그려본다. [그림11]의 오른쪽 그림을 통해 20 미만의 이상치가 잘 제거되었음을 확인한다.



[그림11] 이상치 데이터 제거 전, 제거 후

(9) Min-max 정규화

결측값들과 이상치들을 모두 제거한 후 위에서 확인한 것처럼 다른 열들의 값에 비해 수치가 큰 이완기와 수축기를 Min-max 정규화를 실시한다. [그림12]를 통해 최솟값 60, 최댓값 142, 평균값 96.7을 가지던 수축기는 정규화를 통해 최솟값 0, 최댓값 1, 평균값 0.45를 가지고 최솟값 30, 최댓값 90, 평균값 58을 가지던 이완기는 정규화를 통해 최솟값 0, 최댓값 1, 평균값 0.47을 가지며 정규화가 잘 되었음을 확인한다.

수축기	이완기	총치치아_유무	총치치아_개수_상	총치치아_개수_하	총치발생위험치아_유무	수축기	이완기	총치치아_유무	총치치아_개수_상	총치치아_개수_하	총치발생위험치아_유무
4765.000000	4765.000000	4765.000000	4765.000000	4765.000000	4765.000000	4765.000000	4765.000000	4765.000000	4765.000000	4765.000000	4765.000000
0.447698	0.473204	0.219098	0.280797	0.229171	0.166422	96.711228	58.392235	0.219098	0.280797	0.229171	0.166422
0.124043	0.118989	0.413678	0.794911	0.685055	0.372498	10.171562	7.139340	0.413678	0.794911	0.685055	0.372498
0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	60.000000	30.000000	0.000000	0.000000	0.000000	0.000000
0.365854	0.400000	0.000000	0.000000	0.000000	0.000000	90.000000	54.000000	0.000000	0.000000	0.000000	0.000000
0.439024	0.500000	0.000000	0.000000	0.000000	0.000000	96.000000	60.000000	0.000000	0.000000	0.000000	0.000000
0.512195	0.533333	0.000000	0.000000	0.000000	0.000000	102.000000	62.000000	0.000000	0.000000	0.000000	0.000000
1.000000	1.000000	1.000000	7.000000	6.000000	1.000000	142.000000	90.000000	1.000000	7.000000	6.000000	1.000000

[그림12] 데이터 정규화 전, 후

(10) 데이터 전처리 후 확인

[그림13]을 보며 데이터 전처리 전과 후의 데이터를 비교한다. 전처리 전의 경우 모든 학생이 가지는 학년도의 열을 통해 총 97,787개의 데이터가 있고 열들에 따라 결측값들이 존재하는 것을 확인할 수 있지만 초등학교 데이터를 추출하고 결측값들을 제거하여 총 4,766개의 데이터가 남은 것을 보인다.


<데이터 전처리 전>					<데이터 전처리 후>				
<class 'pandas.core.frame.DataFrame'> RangeIndex: 97787 entries, 0 to 97786 Data columns (total 113 columns):					<class 'pandas.core.frame.DataFrame'> Int64Index: 4766 entries, 12 to 25686 Data columns (total 48 columns):				
#	Column	Non-Null Count	Dtype		#	Column	Non-Null Count	Dtype	
0	학년도	97787 non-null	int64		0	도시규모	4766 non-null	object	
1	최종가중치	97787 non-null	float64		1	시도	4766 non-null	object	
2	학교ID	97787 non-null	int64		2	학교급	4766 non-null	object	
3	strata	97787 non-null	int64		3	학년	4766 non-null	int64	
4	도시규모	97787 non-null	object		4	성별	4766 non-null	object	
5	공학여부	97787 non-null	object		5	키	4766 non-null	float64	
6	시도	97787 non-null	object		6	몸무게	4766 non-null	float64	
7	학교급	97787 non-null	object		7	수축기	4766 non-null	float64	
8	학년	97787 non-null	int64		8	이완기	4766 non-null	float64	
9	반	97787 non-null	int64		9	충치치아_유무	4766 non-null	object	
10	순번	97787 non-null	int64		10	충치치아_개수_상	4766 non-null	int32	
11	성별	97787 non-null	object		11	충치치아_개수_하	4766 non-null	int32	
12	생년월일	97787 non-null	int64		12	충치발생위험치아_유무	4766 non-null	object	
13	건강검진일	97786 non-null	float64		13	충치발생위험치아_개수_상	4766 non-null	int32	
14	키	97787 non-null	float64		14	충치발생위험치아_개수_하	4766 non-null	int32	
15	몸무게	97787 non-null	float64		15	결손치아영구치아_유무	4766 non-null	object	
16	척추	32230 non-null	object		16	결손치아영구치아_개수_상	4766 non-null	int32	
17	시력_나안_좌	20826 non-null	float64		17	결손치아영구치아_개수_하	4766 non-null	int32	
18	시력_나안_우	20826 non-null	float64		18	라면	4766 non-null	int32	
19	시력_교정_좌	11590 non-null	float64		19	음료수	4766 non-null	int32	
20	시력_교정_우	11590 non-null	float64		20	패스트푸드	4766 non-null	int32	
(생략)					(생략)				

[그림13] 데이터 전처리 전, 후

3. 데이터 시각화

(1) Pie Chart

[그림14]는 bmi 비율을 표현한 것으로 전체 성별, 남성, 여성에 따라 bmi_등급의 비율을 각각 표현하였다. 세 부분에서 bmi 정상인 비율이 약 70%의 수치를 가지며 정상이 아닌(저체중, 과체중, 비만) 비율의 합보다 항상 많은 것을 알 수 있다. 또한 정상 bmi가 아닌 경우 과체중 > 비만 > 저체중 순으로 비율을 차지하는 것을 알 수 있다. 전체의 경우 정상이 69.8%로 가장 많았고 저체중의 경우 4.95%로 가장 낮은 비율을 차지하고 있다. 남성의 경우 정상이 68.3%, 저체중이 4.25%로 전체 bmi 등급에서의 정상 비율과 저체중 비율보다 다소 낮은 모습을 보여준다. 반면 과체중, 비만에서는 전체 bmi 등급 비율에서보다 높은 비율을 보인다. 여성의 경우 정상이 71.5%로 가장 많은, 저체중이 5.72%로 가장 적은 비율을 보인다. 전체 bmi 등급 비율에서보다 정상, 저체중의 비율이 높게 보이며 과체중과 비만의 경우 다소 낮은 모습을 보인다.



[그림14] bmi 등급에 따른 Pie Chart

(2) Bar Chart

도시 규모에 따라 성별로 구분하여 bmi가 정상 범주가 아닌 등급을 [그림15]에서 막대그림으로 표현하였다. 대도시/중소도시의 남성의 경우 과체중에서 가장 많았고 저체중에서 가장 적었다. 과체중의 수가 저체중의 수보다 약 3.5배 정도 많았으며 비만의 수가 저체중의 수보다 약 3배 정도 많았다. 여성의 경우 또한 과체중에서 가장 많았고 저체중에서 가장 적었다. 과체중의 수가 저체중의 수보다 약 2배 많았으며 비만의 수가 저체중의 수보다 1.9배 많았다. 남성, 여성 포함하여 남성의 과체중이 가장 많았고 남성의 저체중이 가장 적은 것을 볼 수 있으며 남성의 저체중 대비 체중 과다의 비율이 여성의 저체중 대비 체중 과다의 비율보다 높다. 읍지역의 남성의 경우 비만이 가장 많았고 과체중이 가장 적었다. 과체중의 수가 저체중의 수보다 약 3.3배 많고 비만의 수가 저체중의 수보다 약 3.5배 많다. 여성의 경우 과체중이 가장 많았고 저체중이 가장 적었다. 과체중의 수가 저체중의 수보다 약 3배 많고 비만의 수가 저체중의 수보다 약 2배 많다. 대도시/중소도시의 과체중이 가장 많은 모습과는 다르게 읍지역의 남성의 경우 비만이 가장 많았다. 도서벽지/면지역의 남성의 경우 비만이 가장 많고 저체중이 가장 적었다. 과체중의 수가 저체중의 수보다 약 2배 많고 비만의 수가 저체중의 수보다 약 3배 많다. 여성의 경우 또한 비만이 가장 많고 저체중이 가장 적었다. 과체중의 수가 저체중의 수보다 약 2배 많고 비만의 수가 저체중의 수보다 약 3배 많다. 대도시/중소도시의 모든 성별에서 과체중이 가장 많은 모습과 비교했을 때 도서벽지/면지역은 모든 성별에서 비만이 가장 많다. 모든 지역에서 성별 상관없이 저체중의 수가 가장 적었으며 과다 체중의 수가 가장 많은 것을 알 수 있다.



[그림15] 성별, 도시 규모에 따른 비정상 bmi 등급 barplot

[그림16]은 시도에 따른 비정상 bmi 등급을 표현하였다. 시도는 경기, 광주, 인천, ..., 제주, 전남으로 14개의 지역이 있는 것을 알 수 있다. 비정상 bmi 등급의 수가 가장 많은 지역은 인천이고 가장 적은 지역은 서울인 것을 알 수 있다. 서울의 인구가 가장 많음에도 서울의 비정상 bmi 등급의 수가 가장 적은 것은 결측값 처리 중 서울 데이터가 제거된 것으로 보인다.


경기, 광주, 인천, 경북, 대구, 충남, 경남, 세종, 제주에서 과체중의 수가 가장 높고 비만, 저체중 순으로 저체중의 수가 가장 적은 것을 보인다. 특히 인천, 세종, 제주의 경우 저체중에 비해 과체중, 비만의 수가 눈에 띄게 많은 것을 알 수 있다. 반면 서울, 전북, 대전, 전남의 경우 비만, 과체중, 저체중의 순으로 비만의 수가 가장 많고 저체중의 수가 가장 적은 계단식의 모습을 보인다. 시도에 따른 학생 수는 차이가 있지만 시도에 따라 비정상 bmi의 비율에 차이가 있다고 하기 어렵다.



[그림16] 시도에 따른 비정상 bmi 등급 barplot

(3) Parallel sets Chart

[그림17]은 성별에 따라 이상 치아 유무에 따른 bmi 등급을 표현하였다. 이상 치아 중 충치 치아가 있는 수가 가장 많았으며 결손 치아, 영구 치아가 있는 수가 가장 적었다. 그림을 보면 성별에 따른 충치 치아 유무, 충치 발생 치아 유무, 결손치아영구치아 유무, bmi_등급의 비율이 거의 반반인 것을 확인할 수 있다. 치아의 충치, 충치 발생 위험, 결손 치아를 모두 가진 남성은 없고 여성의 경우 있는 것을 확인할 수 있다. 결손 치아, 영구 치아 유무의 경우 대부분이 없고 bmi 등급 분포 또한 고르게 분포되어 해당 열에 대한 분석은 의미가 없는 것을 알 수 있다. 남성이면서 충치 치아만 존재하고 다른 이상 치아가 없는 경우 대부분 bmi 등급이 정상에 분포하며 충치 치아가 있고 충치 발생 치아가 있는 경우 또한 bmi 등급이 대부분 정상인 값을 가진다. 여성이면서 충치 치아가 있고 다른 이상이 없는 경우 대부분 bmi 등급 정상에 분포하며 충치 치아가 있고 충치 발생 위험 치아가 있는 경우 또한 대부분 bmi 등급 정상에 분포하는 것을 보인다. 이를 통해 이상 치아 유무와 관계없이 bmi_등급에 고르게 분포하는 것을 확인할 수 있어 이상 치아는 bmi_등급에 큰 영향을 끼치지 않는다고 보인다.



[그림17] 성별에 따라 이상 치아의 유무에 따른 bmi 등급

(4) Tree map Chart


[그림18]은 학교생활과 bmi를 시각화한 것으로 도시 규모별 학교생활에 따른 bmi를 Tree map으로 표현하였다. 도시 규모에 따라서는 도서벽지/면지역에서 bmi의 평균이 가장 높게 나타났고 대도시/중소도시에서 가장 낮게 나타났다. 대도시/중소도시에서 현금갈취가 있던 학생들의 bmi 평균은 20 이하였고 현금갈취가 없었던 학생들의 bmi 평균은 20 이상으로 보아 현금갈취는 덩치가 작은 학생들에게 주로 발생한 것으로 보인다. 현금갈취가 없는 학생 중 신체접촉의 경우 bmi의 평균이 높을수록 신체접촉 경험이 있었으며 평균이 낮을수록 신체접촉의 경험이 없는 것을 보인다. 현금갈취 경험이 없고 신체접촉이 있던 학생 중 괴롭힘이 없었던 학생에서 체벌 경험이 있는 학생의 bmi 평균이 체벌 경험이 없는 학생의 bmi 평균보다 높았으며 괴롭힘이 있던 학생에서는 체벌 경험이 없는 학생의 bmi 평균이 높음을 보인다. 도서벽지/면지역의 경우 현금갈취가 있는 학생의 bmi의 평균이 매우 높은 것으로 보이며 그 하위 속성들 또한 모두 높은 것으로 보인다. 현금갈취가 없는 학생 중 신체접촉 경험이 있을 때 없을 때보다 평균 bmi가 높았으며 신체접촉이 없을 때 괴롭힘이 있는 학생이 괴롭힘이 없는 학생보다 bmi의 평균이 높은 것을 볼 수 있다. 도서벽지/면지역에서 현금갈취가 있는 학생, 현금갈취가 없으면서 신체접촉이 없고 괴롭힘당한 적이 있으며 체벌 경험이 있는 학생의 bmi 평균이 높았고 현금갈취가 없으며 신체접촉을 당했고 괴롭힘이 있던 학생의 bmi 평균이 높았다. 반면 현금갈취가 없으며 신체접촉 당한 적이 없고 괴롭힘당한 적 없으며 체벌 경험이 있는 학생의 경우 bmi의 평균이 낮은 것을 보인다. 읍지역의 경우 현금갈취를 당한 적 있는 학생이 없는 학생보다 bmi의 평균이 높았으며 현금갈취가 없고 신체접촉이 있는 학생의 bmi 평균이 낮았고 현금갈취가 없고 신체접촉이 없으며 괴롭힘이 없고 체벌 경험이 있는 학생의 bmi 평균이 다소 높은 것을 보인다. Tree map을 통해 현금갈취, 신체접촉, 괴롭힘, 체벌 경험에 따라 bmi의 평균에서 차이를 보이는 경우도 있으나 그렇지 않은 경우가 더 많아 해당 변수들은 bmi에 큰 영향을 주지 않는 것으로 판단된다.



[그림18] 도시 규모별 학교생활에 따른 bmi

(5) sunburst Chart

[그림19]는 도시 규모별 가정에 따른 bmi 평균을 sunburst Chart로 표현한 그림이다. 상담 O, X는 각각 {상담O : 상담을 희망함, 상담X : 상담을 희망하지 않음}을 의미한다. 도서벽지/면지역의 경우 상담을 희망하는 학생이 희망하지 않는 학생보다 bmi 평균이 높은 것으로 보이며 상담을 희망하는 경우 가족 흡연을 할 때보다 가족 흡연을 하지 않을 때 bmi 평균이 높은 것을 보인다. 상담을 희망하며 가족이 흡연하지 않고 가출 생각이 있을 때 bmi 평균이 높게 나타났으며 특히 가출 생각이 있으면서 가족의 지지를 받을 때 지지를 받지 않을 때보다 bmi의 평균이 다소 높게 나타났다. 상담을 희망하지 않는 학생의 경우 가족 흡연을 할 때 하지 않을 때보다 bmi 평균이 다소 높게 나타났으며 가족 흡연을 하고 가출 생각이 있으면서 가족의 지지를 받을 때 bmi 평균이 높게 나타남을 보인다. 상담 희망을 원하고 가족 흡연이 있을 때와 상담을 희망하지 않고 가족 흡연이 없을 때 bmi의 평균이 대체로 20 이하인 것을 보인다. 읍지역의 경우 상담을 희망할 때 희망하지 않는 경우보다 bmi의 평균이 다소 높은 것을 보이며 가족이 흡연하지 않고 가출 생각이 있으면서 가족의 지지를 받는 경우 bmi의 평균이 25 이상의 높은 수치를 보이며 가출 생각이 없고 가족 지지를 받지 않는 경우 bmi의 평균이 다소 높게 보인다. 상담 희망을 하며 가족 흡연이 있고 가출 생각이 있으면서 가족 지지를 받을 때 bmi 평균이 가장 낮은 것을 볼 수 있다. 대도시/중소도시의 경우 상담 희망 여부와 상관 없이 대부분에서 bmi의 평균이 낮게 나타났으며 그중 상담 희망을 하며 가족 흡연이 있고 가출 생각이 있으면서 가족지지를 받지 않는 학생의 bmi가 23 정도로 가장 높은 평균을 보이고 있다. sunburst 분석을 통해 지역별로 상담 희망, 가족 흡연, 가출 생각, 가족지지에 따라 bmi 평균이 차이를 보이는 경우도 있으나 차이를 보이지 않는 경우도 있어 해당 열들이 bmi에 큰 영향을 주지 않는 것으로 판단된다.



[그림19] 도시 규모별 가정에 따른 bmi sunburst

4. 데이터 분류분석

(1) 분류분석

전처리를 수행한 학생 건강검사 데이터를 이용해 bmi_등급을 분류하는 모델을 생성한다. 분류분석을 위해 target 변수인 bmi_등급 변수를 LabelEncoder()를 통해 인코딩을 실시한다. {과체중 : 0, 비만 : 1, 저체중 : 2, 정상 : 3}으로 인코딩되었다.

전처리를 수행한 학생 건강검사 데이터를 7:3의 비율로 train, test 데이터 셋을 생성하고 train 데이터에서 훈련한 모델을 test 데이터에 적용한다. bmi_등급을 KNN, NA, SVM, DecisionTree, Randomforest, AdaBoost 분류기로 모델을 생성하였다.

KNN의 경우 K의 개수가 39일 때 분류 정확도가 가장 높았으며 분류 정확도는 0.7인 것을 보인다. [그림20]을 보면 K가 10 이하일 때 K가 증가할수록 분류 정확도가 급격하게 증가하는 것을 볼 수 있으나 분류 정확도의 최고치를 달성 후 K의 값이 증가하여도 분류 정확도는 증가하지 않는 것을 볼 수 있다. [그림23]의 KNN 분류 Confusion Matrix를 보면 실제로 과체중이지만 정상으로 분류한 값이 194, 실제로 비만이지만 과체중으로 분류한 값이 1과 정상으로 분류한 값이 177, 실제로 저체중이지만 정상으로 분류한 값이 55, 실제로 정상인데 정상으로 분류한 값이 1003으로 비만인데 과체중으로 분류한 값 1개를 제외하곤 모두 정상으로 분류한 것을 보인다. 정상의 수가 과체중, 저체중, 비만의 수보다 많아 모두 정상으로 분류해도 분류 정확도가 높게 나온 것으로 보인다. KNN 분류의 경우 분류 정확도는 다소 높지만 정상으로 편향된 분류를 수행하여 올바른 분류를 수행했다고 하기 어렵다.

NA의 분류 정확도는 0.079로 매우 낮으며 분류를 전혀 수행하지 못했다고 할 수 있다. [그림23]의 Confusion Matrix를 보면 실제로 과체중인 학생 194명 중 22명만 과체중으로 분류하고 22명은 비만, 150명은 저체중으로 오분류한 것을 볼 수 있다. 실제로 비만인 학생 178명 중 38명만 비만으로 분류하고 34명은 과체중, 105명은 저체중, 1명은 정상으로 오분류하였고, 실제로 저체중인 학생 55명중 51명을 저체중으로 분류하고, 2명을 과체중, 2명을 비만으로 오분류하여 저체중인 학생에 대한 분류는 잘 된 것으로 보인다. 실제로 정상인 학생은 1,003명 중 2명만 정상으로 분류되었고 52명이 과체중, 51명이 비만, 898명이 저체중으로 오분류되어 정상인 학생에 대한 분류가 제대로 수행되지 않은 것을 보인다. NA 분류의 경우 저체중으로 분류한 비율이 높아 저체중으로 편향된 분류를 수행한 것으로 보이고 분류 정확도 또한 매우 낮아 제대로 된 분류를 수행했다고 할 수 없다.

SVM의 분류 정확도는 0.724로 높은 분류 정확도를 보이고 있다. [그림23]의 Confusion Matrix를 보면 KNN과 비슷하게 대부분을 정상으로 분류한 것을 볼 수 있다. 실제로 과체중인 학생 194명 중 3명을 과체중으로 분류하고 13명을 비만, 178명을 정상으로 오분류하였고 실제로 비만인 학생 178명 중 38명을 비만으로 분류하였고 1명을 과체중, 139명을 정상으로 오분류하였다. 저체중인 학생은 55명 중 55명을 모두 정상으로 오분류하였고 정상인 학생 1003명 중 994명을 정상으로 분류하였고 2명을 과체중, 7명을 비만으로 오분류하였다. SVM의 경우 저체중에 대한 분류를 전혀 수행하지 못했지만 KNN과 다르게 거의 모든 값들을 정상으로 분류하지 않았고 분류 정확도 또한 증가하여 정상으로 분류하는 편향이 존재하는 것으로 보이지만 KNN에 비해 훌륭한 분류를 수행했다고 할 수 있다.


DecisionTree의 분류 정확도는 0.56으로 다소 낮은 분류 정확도를 보이고 있다. [그림23]의 Confusion Matrix를 보면 과체중인 학생 194명 중 31명을 과체중으로 분류하였고 43명을

비만, 9명을 저체중, 111명을 정상으로 오분류하였다. 비만인 학생 178명 중 52명을 비만으로 분류하였고 48명을 과체중, 2명을 저체중, 76명을 정상으로 오분류 하였다. 저체중인 학생 55명 중 6명을 저체중으로 분류하였고 과체중을 8명, 비만을 2명, 정상을 39명으로 오분류 하였다. 정상인 학생 1,003명 중 715명을 정상으로 분류하였고 과체중을 127명, 비만을 76명, 저체중을 85명으로 오분류 하였다.

[그림21]을 통해 Randomforest의 분류 정확도는 0.716으로 n이 135일 때 가장 높은 정확도를 보인다. [그림21]을 보면 n이 20 이하일 때 n이 증가할수록 급격하게 증가하다가 최고치에 달성한 후 n이 증가하더라도 정확도는 증가하지 않는 것을 보인다. [그림23]의 Confusion Matrix를 보면 과체중인 학생 중 6명을 정분류 하였고 22명을 비만, 166명을 정상으로 오분류 하였다. 비만인 학생 중 37명을 정분류 하였고 14명을 과체중, 127명을 정상으로 오분류 하였다. 저체중의 경우 1명을 과체중으로, 54명을 정상으로 오분류하여 저체중에 대한 분류를 전혀 수행하지 못하였다. 정상인 학생 중 978명을 정분류 하였고 10명을 과체중, 15명을 비만으로 오분류하였다. Confusion Matrix를 통해 랜덤포레스트 분류는 SVM과 마찬가지로 저체중에 대한 분류를 전혀 수행하지 못한 것을 볼 수 있다. 분류 정확도는 SVM보다 다소 떨어져 아쉬운 결과를 보인다.


마지막으로 AdaBoost의 분류 정확도는 0.722이고 n이 21일 때 가장 높은 정확도를 보인다. [그림22]를 보면 n이 30 이하일 때 n이 증가할수록 분류 정확도가 증가하였는데 n이 31 이상인 경우 n이 증가할수록 오히려 분류 정확도가 급격하게 감소하는 것을 볼 수 있다. [그림23]의 Confusion Matrix를 보면 과체중인 학생 중 33명을 정분류 하였고 31명을 비만, 2명을 저체중, 128명을 정상으로 오분류 하였다. 비만인 학생 중 61명을 정분류 하였고 26명을 과체중, 1명을 저체중, 90명을 정상으로 오분류 하였다. 저체중인 학생 중 1명을 정분류 하였고 1명을 과체중, 2명을 비만, 51명을 정상으로 오분류 하였다. 정상인 학생 중 916명을 정분류 하였고 37명을 과체중, 29명을 비만, 21명을 저체중으로 오분류 하였다. AdaBoost에서도 저체중에 대한 분류가 다소 잘 이루어지지 않은 것을 보인다.

[그림20] K에 따른 KNN 분류 정확도 [그림21] n에 따른 Randomforest 분류 정확도 [그림22] n에 따른 AdaBoost 분류 정확도



[그림23] 모든 열들을 이용한 KNN, NA, SVM, DecisionTree, Randomforest, AdaBoost 분류

6가지의 모델을 이용해 분류를 실시하였다. [그림23]을 이용하여 [그림24]에서 소수점 3자리 까지 정확도를 표현하였고 이를 통해 분류 정확도의 경우 SVM 모델에서 0.724로 가장 높았고 NA 모델에서 0.079로 가장 낮음을 알 수 있다. 분류 정확도 측면에서는 SVM 모델이 가장 우수하다고 할 수 있지만 [그림23]의 Confusion Matrix를 통해 SVM의 경우 저체중에 대한 분류를 전혀 수행하지 못하고 정상에 대한 분류만을 수행하여 정확도가 높다고 판단되고 AdaBoost의 경우 저체중에 대한 분류도 수행하여 정확도는 SVM에 비해 다소 낮지만 AdaBoost의 분류가 더 우수하다고 판단된다.




[그림24] 모든 열을 이용한 모델의 분류 정확도 비교

(2) 분류분석 정확도 향상

학생 건강검사 데이터의 [그림25] heatmap을 그려보았다. 해당 데이터의 열들이 많아 bmi_등급_encoded와의 상관관계가 높은 열들을 확인하기가 어렵다. 위의 그림을 보면 2~4개의 열을 제외하고는 대부분 bmi_등급_encoded와 상관관계가 없는 것으로 보인다. bmi_등급_encoded와 상관관계가 0.15 이상이거나 -0.15 이하인 값들만을 추출하였고 ‘수축기’, ‘이완기’, ‘다이어트경험_답변1’, ‘다이어트경험_답변2’, ‘다이어트경험_답변3’ 열들을 이용해 train, test 데이터 셋을 7:3 비율로 나눠 분류 모델을 생성하였다.

(2) - 1. 상관관계 높은 열 추출



[그림25] 열들 간의 상관관계 및 상관관계 높은 열 추출

KNN의 분류 정확도는 0.7223으로 k가 43일 때 가장 높은 분류 정확도를 가졌으며 모든 데이터를 이용해 분류를 수행했을 때보다 약 0.02 정도 분류 정확도가 증가한 것을 볼 수 있다. [그림26]을 보면 K가 증가할수록 분류 정확도가 약간의 증가세를 보이는 것을 알 수 있고 모든 데이터에 대한 KNN 분류를 수행했을 때 거의 모든 데이터를 정상으로 분류하여 과체중, 저체중, 비만에 대한 분류가 잘 이루어지지 않았는데 상관관계가 높은 열들을 이용할 경우 저체중을 제외한 과체중, 비만에 대한 분류가 잘 수행된 것을 볼 수 있다.

NA의 분류 정확도의 경우 0.67로 모든 데이터를 이용해 분류를 수행했을 때보다 약 0.6 분류 정확도가 증가하며 분류가 이전보다 훌륭하게 수행된 것을 볼 수 있다. 모든 데이터를 이용했을 때 비만, 과체중, 저체중에 대한 분류만 수행되고 정상에 대한 분류가 수행이 안 됐었는데 상관관계가 높은 열들을 이용했을 때 정상에 대한 분류가 잘 수행되어 NA 분류의 경우 상관관계가 낮은 불필요한 열들이 많을 경우 분류를 제대로 수행하지 못하는 것을 알 수 있다.

SVM의 분류 정확도의 경우 0.7로 모든 데이터를 이용해 분류를 수행했을 때보다 약 0.02 감소하여 분류 모델 성능이 더 안 좋아진 것을 볼 수 있다. 모든 데이터를 이용했을 때 저체중에 대한 분류는 수행하지 못했지만 비만, 과체중, 정상에 대한 분류는 수행한 것으로 확인되었는데 상관관계가 낮은 열들을 제거했을 때 비만, 저체중, 과체중에 대한 분류를 전혀 수


행하지 못하고 모든 데이터를 정상으로 분류한 것을 볼 수 있다. SVM의 경우 target의 개수와 열의 개수에 영향을 많이 받는다고 예상할 수 있다.

Decision Tree의 분류 정확도는 0.64로 모든 데이터를 이용해 분류를 수행했을 때보다 약 0.07 증가하여 모델 성능이 좋아진 것을 알 수 있다. 하지만 [그림29]를 보면 모든 데이터를 사용했을 때 저체중인 학생을 6명 정분류 하였는데 열 선택 후 저체중을 모두 오분류한 것을 볼 수 있다. 그 대신 정상인 학생을 약 100명 정도 정분류하여 분류 정확도가 상승한 것으로 보인다.

Random forest의 분류 정확도는 n이 38일 때 가장 높았으며 0.67로 모든 데이터를 사용했을 때보다 약 0.05 감소하며 모델 성능이 안 좋아진 것을 볼 수 있다. [그림27]을 보면 n이 증가할수록 분류 정확도가 증가와 감소를 반복하다가 n이 70 이상일 때부터 감소 추세를 보이며 모든 데이터를 썼을 때 최고치에서 증가 혹은 유지하는 모습과 차이를 보인다. Random forest에서도 저체중을 정분류한 값은 없고 과체중, 비만으로 오분류한 사례가 많아진 것을 볼 수 있다.

Ada Boost의 [그림28] 분류 정확도를 보면 n이 5일 때 0.72로 가장 큰 정확도를 가지며 모든 데이터를 이용해 분류를 수행했을 때보다 0.003 정도 감소한 것을 볼 수 있다. 정확도가 크게 감소한 것이 아니기 때문에 성능이 감소했다고 보긴 어렵지만 이전의 분류에서는 저체중을 1개 정분류 했었는데 열 선택 후 저체중에 대한 분류가 전혀 수행되지 않은 것을 알 수 있다. [그림28]을 보아 n이 증가할수록 정확도는 감소세를 보인다.

[그림26] K에 따른 KNN 분류 정확도



```
[[ 9 24 0 161]
 [ 8 44 0 126]
 [ 0 1 0 54]
 [ 3 24 0 976]]
```


n_estimators : 43

KNN 분류 정확도 Max : 0.7223776223776224

```
Confusion Matrix: [[ 29 36 4 125]
 [ 47 43 1 87]
 [ 4 2 0 49]
 [ 80 51 29 843]]
```

Decision Tree 분류 정확도: 0.6398601398601399

[그림27] n에 따른 Randomforest 분류 정확도



```
[[ 36 55 3 100]
 [ 27 90 0 61]
 [ 1 1 0 53]
 [ 65 85 21 832]]
```


NA 분류 정확도: 0.66993006993007

```
Confusion Matrix: [[ 28 29 1 136]
 [ 30 40 1 107]
 [ 2 1 0 52]
 [ 50 47 19 887]]
```

n_estimators : 38

랜덤 포레스트 분류 정확도: 0.6678321678321678

[그림28] n에 따른 AdaBoost 분류 정확도



```
[[ 0 0 0 194]
 [ 0 0 0 178]
 [ 0 0 0 55]
 [ 0 0 0 1003]]
```

SVC 분류 정확도 : 0.7013986013986014


```
Confusion Matrix: [[ 10 19 1 164]
 [ 17 27 0 134]
 [ 0 1 0 54]
 [ 9 17 0 977]]
```

ada 분류 정확도 : 0.720979020979021

n_estimators : 5

[그림29] 상관관계가 높은 열들 KNN, NA, SVM, DecisionTree, Randomforest, AdaBoost 분류

[그림29]를 통해 [그림30]으로 상관관계가 높은 열들로 분류를 수행한 모델들의 분류 정확도를 소수점 세 자리까지 표현하여 막대그래프로 나타냈다. 6가지 모델 중 KNN에서 분류 정확도가 가장 높았고 Decision Tree에서 분류 정확도가 가장 낮았다. Ada Boost는 모든 열을 썼을 때와 마찬가지로 높은 분류 정확도를 보이고 NA 분류의 분류 정확도는 확연히 증가한 것을 그림으로 볼 수 있다. Decision Tree 또한 증가하였지만 NA에 비해 증가세가 적고 다른 분류 모델에 비해 정확도가 떨어짐을 보인다.



[그림30] 상관관계 높은 열을 이용한 모델의 분류 정확도 비교

(2) - 2. 모델 Stacking

분류 정확도 향상을 위해 모델 Stacking 방법을 실시하였다. 단일 모델에서 우수한 성능을 보였던 SVM, KNN, Ada Boost 모델을 선택하였다. [그림31]을 보면 4개의 Stacking 모델을 수행했음을 알 수 있는데 먼저 SVM과 KNN 분류 모델을 Stacking 하여 Decision Tree 분류를 파악한다. 분류 정확도는 0.58로 기존의 단일 SVM, KNN 모델보다 정확도가 감소한 것을 볼 수 있으나 정상에 대한 분류가 잘 이루어지지 않고 비만, 과체중, 저체중에 대한 분류가 단일 모델에 비해 잘 이루어졌음을 확인할 수 있다.

SVM과 KNN 분류 모델을 Stacking 한 후 위와 다르게 Logistic 분류를 수행하였다. 분류 정확도는 0.723으로 단일 모델 분류 정확도가 KNN보다 상승하였고 SVM보다 다소 감소하였다. Decision Tree와 비교했을 때 분류 정확도가 약 0.14 증가하며 Logistic을 사용했을 때 모델의 성능이 향상하는 것을 보인다. 다만 정상에 대한 분류는 잘 수행됐지만 저체중, 과체중에 대한 분류는 전혀 수행되지 않은 것을 볼 수 있다.


AdaBoost와 SVM 분류 모델을 Stacking 하여 Logistic 분류를 수행하였다. 분류 정확도는 0.72로 단일 모델 SVM보다 정확도가 감소한 것을 보이며 SVM, KNN Stacking에 비해 분류 정확도가 0.01 감소한 것을 보인다. Ada, SVM Stacking 모델 또한 과체중과 저체중에 대한 분류를 전혀 수행하지 못하며 비만과 정상에 대한 분류만을 수행하는 것을 볼 수 있다.

AdaBoost, KNN, SVM 분류 모델을 Stacking 하여 Logistic 분류를 수행하였다. 분류 정확도는 0.723인 단일 SVM 모델보다 분류 정확도가 다소 감소하였고 SVM, KNN Stacking 모델과의 Confusion Matrix를 비교했을 때 동일한 분류와 분류 정확도를 가지는 것을 보인다. 이 모델 또한 과제중과 저체중에 대한 분류를 전혀 수행하지 못하는 것을 볼 수 있다.

Confusion Matrix: $\begin{bmatrix} 37 & 33 & 8 & 116 \\ 43 & 56 & 6 & 73 \\ 3 & 3 & 6 & 43 \\ 113 & 67 & 89 & 734 \end{bmatrix}$ SVM, KNN 스택킹(DecisionTree) 분류 정확도: 0.5825174825174825	Confusion Matrix: $\begin{bmatrix} 0 & 17 & 0 & 177 \\ 0 & 40 & 0 & 138 \\ 0 & 0 & 0 & 55 \\ 0 & 9 & 0 & 994 \end{bmatrix}$ SVM, KNN 스택킹(Logistic) 분류 정확도: 0.7230769230769231
Confusion Matrix: $\begin{bmatrix} 0 & 16 & 0 & 178 \\ 0 & 39 & 0 & 139 \\ 0 & 0 & 0 & 55 \\ 0 & 9 & 0 & 994 \end{bmatrix}$ ADA, SVM 스택킹(Logistic) 분류 정확도: 0.7223776223776224	Confusion Matrix: $\begin{bmatrix} 0 & 17 & 0 & 177 \\ 0 & 40 & 0 & 138 \\ 0 & 0 & 0 & 55 \\ 0 & 9 & 0 & 994 \end{bmatrix}$ ADA, KNN, SVM 스택킹(Logistic) 분류 정확도: 0.7230769230769231

[그림31] 모델 Stacking

[그림31]을 통해 [그림32]로 모델에 따라 분류 정확도를 소수점 3자리까지 표현하며 비교하였다. SVM, KNN Stacking(Logistic)과 ADA, KNN, SVM Stacking(Logistic)의 모델에서 분류 정확도가 0.723으로 가장 높았으며 SVM, KNN Stacking(Decision Tree)의 모델에서 분류 정확도가 0.592로 가장 낮았다. 해당 데이터의 분류 Logistic 분류가 Decision Tree 분류보다 우수한 성능을 보였고 모델 Stacking을 했을 때 단일 모델 SVM보다는 정확도가 다소 감소한 것을 보여준다.



[그림32] Stacking 후 모델의 분류 정확도 비교

IV. 연구 결과

1. 연구 요약


학생 건강검사 데이터를 KNN, NA, SVM, Decision Tree, Random forest, Ada Boost 모델을 이용해 비만, 과체중, 저체중, 정상으로 분류하는 분석을 실시하였다. 상관관계가 낮은 열들을 모두 포함하여 분류를 수행했을 때 SVM을 이용한 분류의 정확도가 0.724로 가장 높았고 NA를 이용한 분류의 정확도가 0.08로 가장 낮았다. KNN, Random forest, Ada Boost의 K, N, N의 크기는 각각 39, 135, 21일 때 분류 정확도가 가장 높았으며 Ada Boost의 경우 N의 크기가 20 이상일 때 증가할수록 정확도가 감소하는 모습을 보였다. NA, Decision Tree, Ada Boost를 제외한 모델에서 저체중에 대한 분류를 전혀 수행하지 못하였고 특히 KNN의 경우 저체중뿐 아니라 과체중, 비만에 대한 분류도 제대로 수행하지 못해 1명을 제외한 모든 학생을 정상으로 분류하였다. 반대로 NA 분류는 정상인 학생에 대한 분류를 거의 수행하지 못하였고 과체중, 비만, 저체중 학생에 대한 분류만을 수행하였다.

분류 정확도 향상을 위해 상관관계가 상대적으로 높은 열들만 추출하여 6가지 분류를 다시 수행하였다. KNN 분류의 정확도가 0.722로 가장 높았으며 Decision Tree 분류의 정확도가 0.64로 가장 낮았다. KNN, Random forest, Ada Boost의 K, N, N의 크기는 각각 43, 38, 5일 때 분류 정확도가 가장 높았으며 Random forest의 경우 N이 증가할수록 정확도가 증가 추세를 보이지만 증가와 감소의 반복을 보이고 Ada Boost의 경우 N이 증가할수록 정확도가 감소하는 추세를 보인다. NA의 경우 상관관계가 낮은 모든 열을 사용했을 때보다 분류 정확도가 급격히 상승한 것을 볼 수 있고 이전에 정상에 대한 분류를 전혀 수행하지 못했는데 이를 개선한 것으로 보인다.

다음으로 모델 Stacking을 실시하였다. Stacking 후 Decision Tree를 이용한 분류보다 Logistic 분류가 성능이 더 좋았으며 SVM, KNN 모델을 Stacking 하여 Logistic 분류했을 때 분류의 정확도가 0.723으로 가장 높았으며 SVM, KNN 모델을 Stacking 하여 Decision Tree 분류했을 때 분류 정확도가 0.58로 가장 낮았다. SVM, KNN 모델을 Stacking 하여 Decision Tree 분류했을 때 비만, 과체중, 저체중에 대한 분류를 잘 수행하는 것을 보이지만 Logistic 분류를 했을 때 과체중과 저체중에 대한 분류를 잘 수행하지 못하는 것을 보인다.

모든 열, 상관관계가 높은 열, Stacking을 이용한 모델 중 각 정확도 상위 3개의 모델을 가져와 소수점 3자리까지 나타내 색으로 구분하여 [그림33]으로 비교하였다. 전체 모델 중 단일 모델인 모든 열들을 이용한 SVM 분류가 성능이 가장 좋았으며 SVM, KNN Stacking(Logistic)과 ADA, KNN, SVM Stacking(Logistic)이 그 뒤를 이었고 상관관계가 높은 열들을 이용한 SVM 분류 모델에서 다소 아쉬운 분류 정확도를 보였다. 최악의 모델은 모든 열들을 이용한 NA 분류이며 단일 모델의 성능을 향상시키고자 모델 Stacking을 수행하였으나 성능이 단일 모델과 크게 다르지 않아 단일 모델로도 충분히 데이터를 분류할 수 있어 단일 모델을 선택한다. 대부분의 모델에서 정상에 대한 분류는 잘 수행하였지만 비만, 과체중, 저체중에 대한 분류는 잘 수행하지 못하는데 특히 저체중에 대한 분류를 전혀 수행하지 못하는 모델들이 있었다. 단순히 분류 정확도 측면에서 보면 SVM 분류가 가장 좋으나 해당 분류는 정상과 비만에 대한 분류만 잘 수행하여 성능이 좋다고 말하기에 한계가 있어 보인다. 반면 Ada Boost의 경우 분류 정확도는 SVM에 비해 다소 떨어지나 정상과 비만뿐 아니라 과체중에 대해 분류를 잘 수행했기에 Ada Boost의 모델을 선택한다.

해당 연구는 분류분석을 함으로써 분류의 정확도를 향상시키고 청소년의 생활에 따라 비만, 정상, 과체중, 저체중으로 예측을 정확하게 수행하는 것을 목적으로 하였다. 다양한 모델을 통해 분류분석을 수행하여도 정확도는 크게 증가하지 않았지만 정상체중만을 분류하던 모델들이 과체중, 비만 체중도 분류를 수행하여 모델 성능 향상 작업이 효과가 있었다고 판단된다. 해당 연구를 통해 청소년의 식습관뿐 아니라 학교생활, 가정생활, 학생의 심리 등을 통해 청소년 비만을 분류, 예측하고 이를 기반으로 학생이 정상체중에서 과체중, 비만 단계로 넘어가기 전 학생의 비만 위험을 미리 파악하고 교육청, 학교, 가정 측면에서 교육, 교정을 통해 체중의 증가를 막을 수 있어 비만 청소년의 증가세를 감소시키는 기대를 할 수 있을 것이다.



[그림33] 모든 열, 상관관계 높은 열, Stacking 모델 중 각각 정확도 상위 3개의 모델을 비교

2. 연구의 한계점

해당 연구의 가장 큰 한계점은 데이터이다. 연구에 사용한 데이터는 학교에서 필수적으로 실시하는 학생 건강검사 데이터로 학교에서 직접 검사를 통해 작성된 키, 몸무게, 시력 등을 제외한 식습관에 대한 항목, 가정에 대한 항목, 학교생활에 대한 항목은 학생들이 직접 수기로 작성하는 것으로 강제로 하는 검사이기에 실제 작성 모습을 보면 학생들이 한 번으로 작성하거나 고의로 극단 값을 작성하는 경우, 실제로 문제가 있음에도 후에 발생할 상황으로 문제가 없다고 하는 등이 많다. 따라서 데이터에 대한 신뢰가 부족하다. 직접 검사를 통해 작성되었음에도 학생에 따라 결측값이 너무 많아 유의미한 데이터임에도 분석에 사용하지 못한 데이터도 있었다.

다음으로 분류 분석하려는 target 데이터의 비율이다. [그림14] Pie Chart를 보면 전체 Bmi_등급 중 70%가 정상인 반면 저체중은 5%로 정상에 비해 데이터의 수가 매우 적으며 정상이 Bmi_등급에서 차지하는 비율이 매우 높다. 위의 분석 결과를 보면 대부분의 모델에서 저체중에 대한 분류를 전혀 수행하지 못하고 정상에 대한 분류를 잘 수행하는 것을 보이는데 이는 정상의 비율이 매우 높고 저체중의 비율이 매우 낮아 생기는 문제이다. 특히 정상에 대한 비율이 너무 높아 모두 정상으로 분류했음에도 정확도가 0.7이 나오며 후에 들어오는 데이터들 모두 정상으로 분류하는 오류가 발생할 수 있다. 이에 모델에 대한 결론을 내리기엔 성급하다. 연구가 지속된다면 설문지를 직접 작성하여 자발적인 설문을 통해 신뢰 높은 데이터를 충분히 수집 후 다양한 변수들을 추가하며 모델에 대한 신뢰와 성능을 높여 청소년 비만 감소에 기여할 수 있을 것이다.

참고문헌

1. 논문

장아영. "청소년의 건강과 학교생활적응의 관계." 국내석사학위논문 전북대학교 일반대학원, 2018. 전라북도

이은숙. "정상체중청소년과 비만청소년의 신체활동과 그에 관련된 동기적 특성." 국내석사학위논문 서울산업대학교 산업 대학원, 2008. 서울

최유경. "비만청소년과 비비만 청소년의 성격차이 분석." 국내석사학위논문 고려대학교 교육대학원, 2008. 서울

정영호, 고숙자, 임희진. "청소년 비만의 사회경제적 비용." 보건사회연구, 2010

2. 뉴스

컬처IN:2035년 세계 인구 절반 과체중...아동·청소년 비만 경고등(Special Broadcasting Service, 2023)

10년 뒤 중고생 3분의 1은 비만?...“적극적인 정책 접근 필요”(메디포뉴스, 2023)

중고등학생 비만을 현황 (출처 : 경향신문, 연합뉴스 2023, 자료 : 질병관리청)

3. 통계 데이터

청소년 비만 현황(KOSIS)

4. 사전

비만에 의한 질환, 청소년 비만의 문제점(대한 비만 학회)

비만의 정의(네이버 지식백과-서울대학교 병원 의학 정보)